

# 第三章 非线性规划

- 3.1 例子和预备知识
- 3.2 凸集、凸函数和凸规划
- 3.3 非线性规划的库恩-塔克定理
- 3.4 单变量极值问题的解法
- 3.5 无约束极值问题的解法
- 3.6 罚函数法
- 3.7 线性约束下线性逼近的方法

# 3.1 例子和预备知识

- 在科学管理和其他领域中，很多实际问题可归结为线性规划问题. 但也有很多问题，其目标函数或约束条件不是线性函数. 如果目标函数或约束条件中含有非线性函数，就称这种问题为非线性规划问题.
- 解这类问题需要用非线性规划方法. 非线性规划已成为运筹学一个重要分支，在最优设计、管理科学、系统控制等许多领域获得越来越广泛的应用.
- 一般说来，由于非线性函数的复杂性，解非线性规划问题远比解线性规划问题困难得多. 而且，也不像线性规划那样有单纯形法等通用方法. 非线性规划目前还没有一般性算法，各个方法都有自己特定的适用范围.

## 1. 非线性规划的标准形式

$$(P) \quad \min f(x), x \in \mathbb{R}^n$$

$$\begin{cases} g_1(x) & \geq & 0 \\ g_2(x) & \geq & 0 \\ \dots & \dots & \\ g_m(x) & \geq & 0 \end{cases}$$

**例1.** 给定一根长400米的绳子，用来围成一块矩形菜地，问长和宽各为多少米时，可以使菜地的面积最大？

解：设长为 $x_1$ 米，宽为 $x_2$ 米. 规划问题为

$$\begin{array}{ccc} \max x_1 x_2 & & \min -x_1 x_2 \\ \left\{ \begin{array}{l} 2(x_1 + x_2) = 400 \\ x_1 \geq 0 \\ x_2 \geq 0 \end{array} \right. & \longleftrightarrow & \left\{ \begin{array}{l} 2(x_1 + x_2) \geq 400 \\ -[2(x_1 + x_2)] \geq 400 \\ x_1 \geq 0 \\ x_2 \geq 0 \end{array} \right. \end{array}$$

## 2. 极值点存在的必要条件

设  $f : R \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$  ,  $x_0 \in R$  . 如果  $f$  在  $x_0$  取得局部极值且在  $x_0$  各偏导数存在, 则必有

$$\frac{\partial f(x_0)}{\partial x_1} = \frac{\partial f(x_0)}{\partial x_2} = \dots = \frac{\partial f(x_0)}{\partial x_n} = 0$$

或

$$\nabla f(x_0) = 0$$

上式中

$$\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$$

## 极值点存在的充分条件

设  $f$  在  $R \subseteq \mathbb{R}^n$  上有连续的二阶偏导函数,  $x_0 \in R$ . 若  $\nabla f(x_0) = 0$ , 且对任何  $0 \neq y \in \mathbb{R}^n$  有

$$y^T H(x_0) y > 0$$

则  $x_0$  为  $f$  的严格局部极小点. 类似的, 若有  $y^T H(x_0) y < 0$ , 则  $x_0$  为  $f$  的严格局部极大点.

这里  $H(x_0)$  为  $f$  在点  $x_0$  处的海赛(Hesse)矩阵

$$H(x_0) = \begin{bmatrix} \frac{\partial^2 f}{\partial^2 x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial^2 x_2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial^2 x_n} \end{bmatrix} \Big|_{x_0}$$

## 3.2 凸函数和凸规划

### • 定义

设  $f(x)$  为定义在  $n$  维欧式空间  $\mathbb{R}^n$  中的某个凸集  $S$  上的函数, 若对任何实数  $0 < \alpha < 1$  以及  $x, y \in S$ , 恒有

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$$

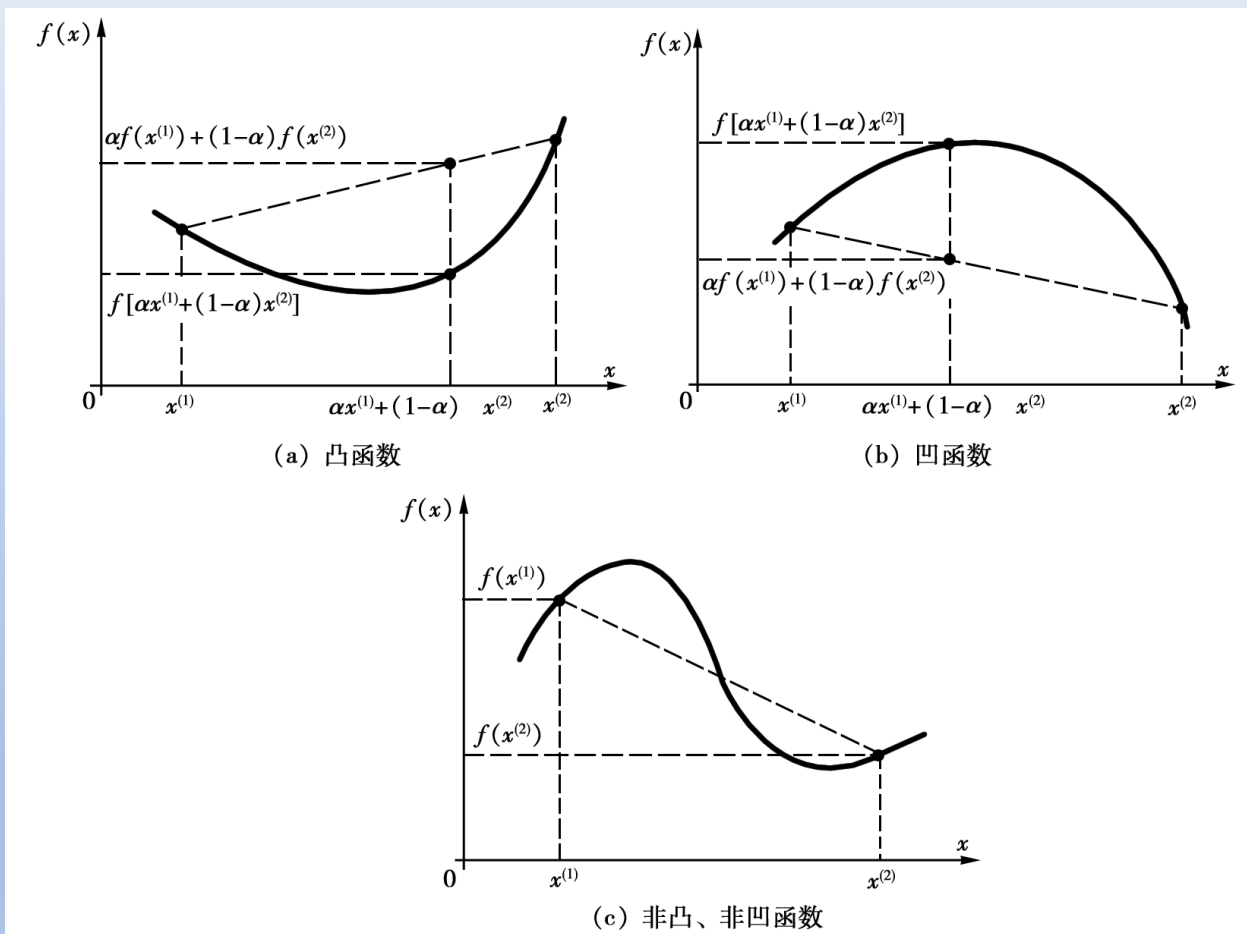
则称  $f(x)$  为定义在  $S$  上的凸函数.

若对任何实数  $0 < \alpha < 1$  以及  $x \neq y \in S$ , 恒有

$$f(\alpha x + (1 - \alpha)y) < \alpha f(x) + (1 - \alpha)f(y)$$

则称  $f(x)$  为定义在  $S$  上的严格凸函数.

类似可以定义凸集S上的凹函数. 显然,  $f$ 是凸函数  $\longleftrightarrow -f$ 是凹函数.



凸函数的基本性质:

给定凸集  $S \subseteq E^n$

1.  $f(x)$ 为 $S$ 上的凸函数当且仅当对于 $x, y \in S$ , 一元函数

$$h(\alpha) := f(\alpha x + (1 - \alpha)y) = f(y + \alpha(x - y))$$

是 $[0, 1]$ 上的凸函数.

2. 若  $f_1, f_2, \dots, f_m$  为 $S$ 上的凸函数, 那么它们的任意非负线性组合

$$k_1 f_1 + k_2 f_2 + \dots + k_m f_m$$

$k_i \geq 0$ , 仍然是 $S$ 上的凸函数.

3. 设 $f(x)$ 为定义在凸集 $S$ 上的凸函数, 则对任意实数 $\beta$ , 集合

$$S_\beta = \{x \in S | f(x) \leq \beta\}$$

是凸集.



## 可微凸函数的判别准则

给定凸区域  $S \subseteq \mathbb{R}^n$ ,

**定理1.** 假设 $f$ 是 $S$ 上的有连续一阶偏导数的函数, 那么 $f$ 是凸函数的充分必要条件是: 对于任意  $x, y \in S$ , 有

$$f(x) + \nabla f(x) \cdot (y - x) \leq f(y).$$

- $z = f(x)$  和  $z = f(x_0) + \nabla f(x_0) \cdot (x - x_0)$  分别给出函数图像和函数在  $(x_0, f(x_0))$  处切面方程. 定理是说对于凸函数, 切面总在函数图像的下方.

**定理2.** 设 $f$ 有连续的二阶偏导函数, 那么 $f$ 是 $S$ 上的凸函数的充分必要条件是: 对于任意  $x \in S$ ,  $f$ 的Hesse矩阵

$$H(x_0) = \left[ \begin{array}{cccc} \frac{\partial^2 f}{\partial^2 x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial^2 x_2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial^2 x_n} \end{array} \right] \Big|_{x_0}$$

是半正定的.

➤ 一个 $n$ 阶方阵 $A$ 称为半正定的, 如果对所有  $x \in \mathbb{R}^n$ , 有  $x^T A x \geq 0$  成立.

一般而言，函数的局部极小值并不一定等于它的最小值，前者只不过反映了函数的局部性质。而最优化的目的，往往是要要求函数在整个域中的最小值(或最大值). 为此, 必须将所得的全部极小值进行比较(如果有边界，还需考虑边界值)，以便从中选出最小者. 然而，对于定义在凸集上的凸函数来说，则用不着进行这种麻烦的工作，它的局部极小值就等于其最小值.

**定理3.** 若 $f(X)$ 为定义在凸集 $R$ 上的凸函数，则它的任一极小点也是它在 $R$ 上的最小点（全局极小点），而且极小点集为凸集.

证明：设 $x_0$ 是一个局部极小点，则对于充分小的邻域 $B_\delta(x_0)$  中的 $x$ ，均有

$$f(x_0) \leq f(x)$$

对于任意  $y \in R$ , 对于充分小的 $\lambda$ , 有  $\lambda y + (1 - \lambda)x_0 \in B_\delta(x_0)$ . 结合凸函数性质，有

$$\lambda f(y) + (1 - \lambda)f(x_0) \geq f(\lambda y + (1 - \lambda)x_0) \geq f(x_0)$$

整理、移项后除以 $\lambda$ ，得

$$f(y) \geq f(x_0).$$

这就是说， $x_0$  是全局极小点.

定义. 考虑标准形式的规划问题(P):

$$\min f(x), x \in E^n$$

$$\begin{cases} g_1(x) & \geq & 0 \\ g_2(x) & \geq & 0 \\ \dots & \dots & \\ g_m(x) & \geq & 0 \end{cases}$$

如果 $f$ 为凸函数,  $g_i(x), i = 1, 2, \dots, m$  为凹函数, 那么称规划问题(P) 为凸规划.

称集合

$$R = \{x \in \mathbb{R}^n | g_i(x) \geq 0, i = 1, 2, \dots, m\}$$

为约束集合或可行解集.

凸规划是一类简单而又具有重要意义的非线性规划. 线性规划也属于凸规划.

例2. 分析非线性规划问题

$$\begin{aligned} \min f(x) &= x_1^2 + 2x_2^2 - 4x_1 + 6 \\ \begin{cases} g_1(x) &= 2x_1 - x_2 + 1 \geq 0 \\ g_2(x) &= -x_1^2 + x_2 - 3 \geq 0 \\ x_1, x_2 &\geq 0 \end{cases} \end{aligned}$$

解：目标和约束函数都是光滑函数.

$$H(f) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$$

是正定的，故 $f$ 是凸函数.

$$H(g_2) = \begin{bmatrix} \frac{\partial^2 g_2}{\partial x_1^2} & \frac{\partial^2 g_2}{\partial x_1 \partial x_2} \\ \frac{\partial^2 g_2}{\partial x_2 \partial x_1} & \frac{\partial^2 g_2}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} -2 & 0 \\ 0 & 0 \end{bmatrix}$$

是半负定，故 $g_2$ 是凹函数. 所以考虑问题是凸规划.

**定理4.** 设规划问题(P)为凸规划, 那么

- 可行解集 $R$ 为凸集.
- 任何局部最优解即为全局最优解.
- 其最优解的集合形成一个凸子集 $R^*$ .
- 当目标函数 $f(X)$ 为严格凸函数, 且 $R^*$ 非空, 那么最优解必定唯一.

**定理5.** 设(P)为凸规划问题且目标函数 $f$ 有连续一阶偏导数, 则  $x_0 \in R$  是最优解的充分必要条件是: 对于任意  $x \in R$ , 有

$$\nabla f(x_0) \cdot (x - x_0) \geq 0$$

## 3.3 库恩-塔克定理

- 非线性规划中的Kuhn-Tucker定理是非线性规划中重要工具. 它是Lagrange乘数法的推广.
- Kuhn-Tucker条件是某点为非线性规划最优解的一个必要条件（在一定正则性假设下）.
- 对于凸规划，它既是最优点存在的必要条件，同时也是充分条件.

## Lagrange乘数法回顾

求满足约束的极值问题

$$\begin{cases} \min(\max) f(x), & x \in \mathbb{R}^n \\ g_i(x) = 0, & i = 1, 2, \dots, m \end{cases}$$

定义辅助函数  $\varphi(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i g_i(x)$ . 在一定正则性假设下,  $\bar{x}$  是该问题解的一个必要条件是:

存在  $\bar{\lambda} = (\bar{\lambda}_1, \bar{\lambda}_2, \dots, \bar{\lambda}_m)^T$  满足Lagrange条件

$$\begin{cases} \nabla_x \varphi(\bar{x}, \bar{\lambda}) = 0 \\ \nabla_\lambda \varphi(\bar{x}, \bar{\lambda}) = 0 \end{cases}$$

即


$$\begin{cases} \nabla f(\bar{x}) - \sum_{i=1}^m \bar{\lambda}_i \nabla g_i(\bar{x}) = 0 \\ g_i(\bar{x}) = 0 & i = 1, 2, \dots, m \end{cases}$$



非线性规划示意：设 $n=m=2$

$$\begin{cases} \min f(x), & x \in \mathbb{R}^2 \\ g_1(x) \geq 0, & g_2(x) \geq 0 \end{cases}$$


假设 $x^*$ 是最优解.



- a. 若  $g_1(x^*) = 0, g_2(x^*) \neq 0$  那么有满足  $\mu_1^* \geq 0$ ,

$$\nabla f(x^*) = \mu_1^* \nabla g_1(x^*)$$

另一种情形类似.



- b. 若  $g_1(x^*) = g_2(x^*) = 0$ , 那么存在  $\mu_1^* \geq 0, \mu_2^* \geq 0$ , 满足

$$\nabla f(x^*) = \mu_1^* \nabla g_1(x^*) + \mu_2^* \nabla g_2(x^*)$$

## Kuhn-Tucker (K-T) 条件

考虑辅助函数  $\varphi(x, \mu) = f(x) - \sum_{i=1}^m \mu_i g_i(x)$  . 称  $(\bar{x}, \bar{\mu}) \in \mathbb{R}^n \times \mathbb{R}^m$  满足 (K-T) 条件, 如果

$$\begin{cases} \nabla_x \varphi(\bar{x}, \bar{\mu}) &= 0 \\ \nabla_{\mu} \varphi(\bar{x}, \bar{\mu}) &\leq 0 \\ \bar{u} &\geq 0 \\ \bar{u}^T \nabla_{\mu} \varphi(\bar{x}, \bar{\mu}) &= 0 \end{cases}$$

成立.

等价的,

$$\begin{cases} \nabla f(\bar{x}) - \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) = 0 \\ g_i(\bar{x}) \geq 0 & i = 1, 2, \dots, m \\ \bar{\mu}_i \geq 0, & i = 1, 2, \dots, m \\ \bar{\mu}_i g_i(\bar{x}) = 0 & i = 1, 2, \dots, m \end{cases}$$

➤ 有的文献也称Karush-Kuhn-Tucker (KKT)条件.

考虑标准形式的凸规划

$$\begin{cases} \min f(x) & , \quad x \in \mathbb{R}^n \\ g_i(x) \geq 0 & , \quad i = 1, 2, \dots, m \end{cases}$$

**定理6.** 假设  $f, g_i, i = 1, 2, \dots, m$  有连续的一阶偏导函数. 如果  $(\bar{x}, \bar{\mu})$  满足(K-T) 条件, 那么  $\bar{x}$  是凸规划问题的最优解.

**定理7.** 假设如上.  $R$ 为可行解集. 如果存在  $x_0 \in R$  满足

$$g_i(x_0) > 0, i = 1, 2, \dots, m$$

那么如果  $\bar{x}$  是凸规划问题的最优解, 则一定存在  $\bar{u}$ , 使得  $(\bar{x}, \bar{\mu})$  满足(K-T) 条件.

➤ 上述定理说明: 在一定的正则性假设下, 如函数的可导性、可行解集非“蜕化”性, 那么  $\bar{x}$  是凸规划的最优解的充分必要条件是它满足(K-T)条件.

定理6证明：假设  $(\bar{x}, \bar{\mu})$  满足(K-T) 条件. 令

$$E(\bar{x}) = \{i \mid g_i(\bar{x}) = 0, 1 \leq i \leq m\}$$

若  $i \notin E(\bar{x})$ , 有  $g_i(\bar{x}) > 0$ . 由(K-T) 条件, 得  $\bar{\mu}_i = 0$ , 以及

$$\nabla f(\bar{x}) = \sum_{i=1}^m \bar{\mu}_i \nabla g_i(\bar{x}) = \sum_{i \in E(\bar{x})}^m \bar{\mu}_i \nabla g_i(\bar{x})$$

对  $x \in R$ , 有

$$\nabla f(\bar{x}) \cdot (x - \bar{x}) = \sum_{i \in E(\bar{x})}^m \bar{\mu}_i \nabla g_i(\bar{x}) \cdot (x - \bar{x})$$

注意到  $g_i$  为凹函数, 有

$$0 \leq g_i(x) \leq g_i(\bar{x}) + \nabla g_i(\bar{x}) \cdot (x - \bar{x}) = \nabla g_i(\bar{x}) \cdot (x - \bar{x}).$$

从而

$$\nabla f(\bar{x}) \cdot (x - \bar{x}) \geq 0$$

由定理5,  $\bar{x}$  为凸规划的最优解.

例3. 用库恩 - 塔克条件解非线性规划

$$\begin{cases} \min f(x) = (x-3)^2 \\ 0 \leq x \leq 5 \end{cases}$$

解： 先将该非线性规划问题写成以下形式

$$\begin{cases} \min f(x) = (x-3)^2 \\ g_1(x) = x \geq 0 \\ g_2(x) = 5-x \geq 0 \end{cases}$$

写出其目标函数和约束函数的梯度

$$\begin{aligned} \nabla f(x) &= 2(x-3), \\ \nabla g_1(x) &= 1, \nabla g_2(x) = -1 \end{aligned}$$

对第一个和第二个约束条件分别引入K-T乘子，设K-T点为 $x^*$ ，则可以得到该问题的K-T条件.

该问题的K-T条件为:

$$\left\{ \begin{array}{rcl} 2(\bar{x} - 3) - \bar{\mu}_1 + \bar{\mu}_2 & = & 0 \\ \bar{x} & \geq & 0 \\ 5 - \bar{x} & \geq & 0 \\ \bar{\mu}_1, \bar{\mu}_2 & \geq & 0 \\ \bar{\mu}_1 \bar{x} & = & 0 \\ \bar{\mu}_2 (5 - \bar{x}) & = & 0 \end{array} \right.$$

为解上述方程组, 考虑以下几种情形

- (1) 若  $\bar{\mu}_1 \neq 0, \bar{\mu}_2 \neq 0$ , 无解.
- (2) 若  $\bar{\mu}_1 \neq 0, \bar{\mu}_2 = 0$ , 得  $\bar{x} = 0, \bar{\mu}_1 = -6$ , 不是K-T点.
- (3) 若  $\bar{\mu}_1 = 0, \bar{\mu}_2 \neq 0$ , 得  $\bar{x} = 5, \bar{\mu}_2 = -4$ , 不是K-T点.
- (4) 若  $\bar{\mu}_1 = \bar{\mu}_2 = 0$ , 得  $\bar{x} = 3$ , 此为K-T点, 其目标函数值  $f(\bar{x}) = 0$ .

由于该非线性规划问题为凸规划, 故  $\bar{x} = 3$  就是其全局极小点. 该点是可行域的内点, 它也可直接由梯度等于零的条件求出.

例4. 考虑凸规划问题

$$\begin{cases} \min (-x_1 - x_2) \\ 3x_1^2 + x_2^2 \leq 1 \end{cases}$$

解:

$$\nabla f = (-1, -1)^T, \nabla g = (-6x_1, -2x_2)^T$$

K-T条件为

$$\begin{cases} -1 + 6\bar{\mu}\bar{x}_1 & = & 0 \\ -1 + 2\bar{\mu}\bar{x}_2 & = & 0 \\ 1 - 3\bar{x}_1^2 - \bar{x}_2^2 & \geq & 0 \\ \bar{\mu} & \geq & 0 \\ \bar{\mu}(1 - 3\bar{x}_1^2 - \bar{x}_2^2) & = & 0 \end{cases}$$

若  $\bar{\mu} = 0$ , 则  $-1 = 0$ , 矛盾.

若  $\bar{\mu} > 0$ , 则  $1 - 3\bar{x}_1^2 - \bar{x}_2^2 = 0$ . 由前两式得  $\bar{x}_2 = 3\bar{x}_1 > 0$ . 故可解得

$$\bar{x}_1 = \sqrt{\frac{1}{12}}, \bar{x}_2 = 3\sqrt{\frac{1}{12}}, \bar{\mu} = \frac{\sqrt{3}}{3}.$$

凸规划最优解为  $\bar{x}_1 = \sqrt{\frac{1}{12}}, \bar{x}_2 = 3\sqrt{\frac{1}{12}}$ .