

# 第三章 非线性规划

- 3.1 例子和预备知识
- 3.2 凸集、凸函数和凸规划
- 3.3 非线性规划的库恩-塔克定理
- 3.4 单变量极值问题的解法
- 3.5 无约束极值问题的解法
- 3.6 罚函数法
- 3.7\* 线性约束下线性逼近的方法

## 3.4单变量极值问题的解法

在处理一般的非线性规划问题

$$\begin{cases} \min f(x) & , \quad x \in \mathbb{R}^n \\ g_i(x) \geq 0 & , \quad i = 1, 2, \dots, m \end{cases}$$

的算法中常常会遇到情形：求一元函数极值问题

$$\min_{\lambda \geq 0} f(x_k + \lambda z_k)$$

这里  $x_k, z_k \in \mathbb{R}^n$  分别表示第k步得到的点和进一步探寻极值的方向.

有必要讨论一元函数无约束极值问题的算法.

### 3.4.1 “成功-失败” 法

$$\min_{\lambda \in \mathbb{R}^1} f(\lambda)$$

选取初始点 $\lambda_0$ 和步长 $h$ .

如果  $f(\lambda_0 + h) < f(\lambda_0)$ , 则搜索 “成功” . 当前点变为  $\lambda_0 + h$  , 步长放大为 $2h$ . 再比较  $f(\lambda_0 + h)$  和  $f((\lambda_0 + h) + 2h)$ .

如果  $f(\lambda_0 + h) \geq f(\lambda_0)$ , 则搜索 “失败” . 当前点仍然为 $\lambda_0$  , 搜索方向改变, 步长变为先前步长的 $\frac{1}{4}$ . 再比较  $f(\lambda_0)$  和  $f(\lambda_0 - \frac{h}{4})$ .

重复上述过程, 直到步长小于一开始设定的允许误差 $\epsilon > 0$ .

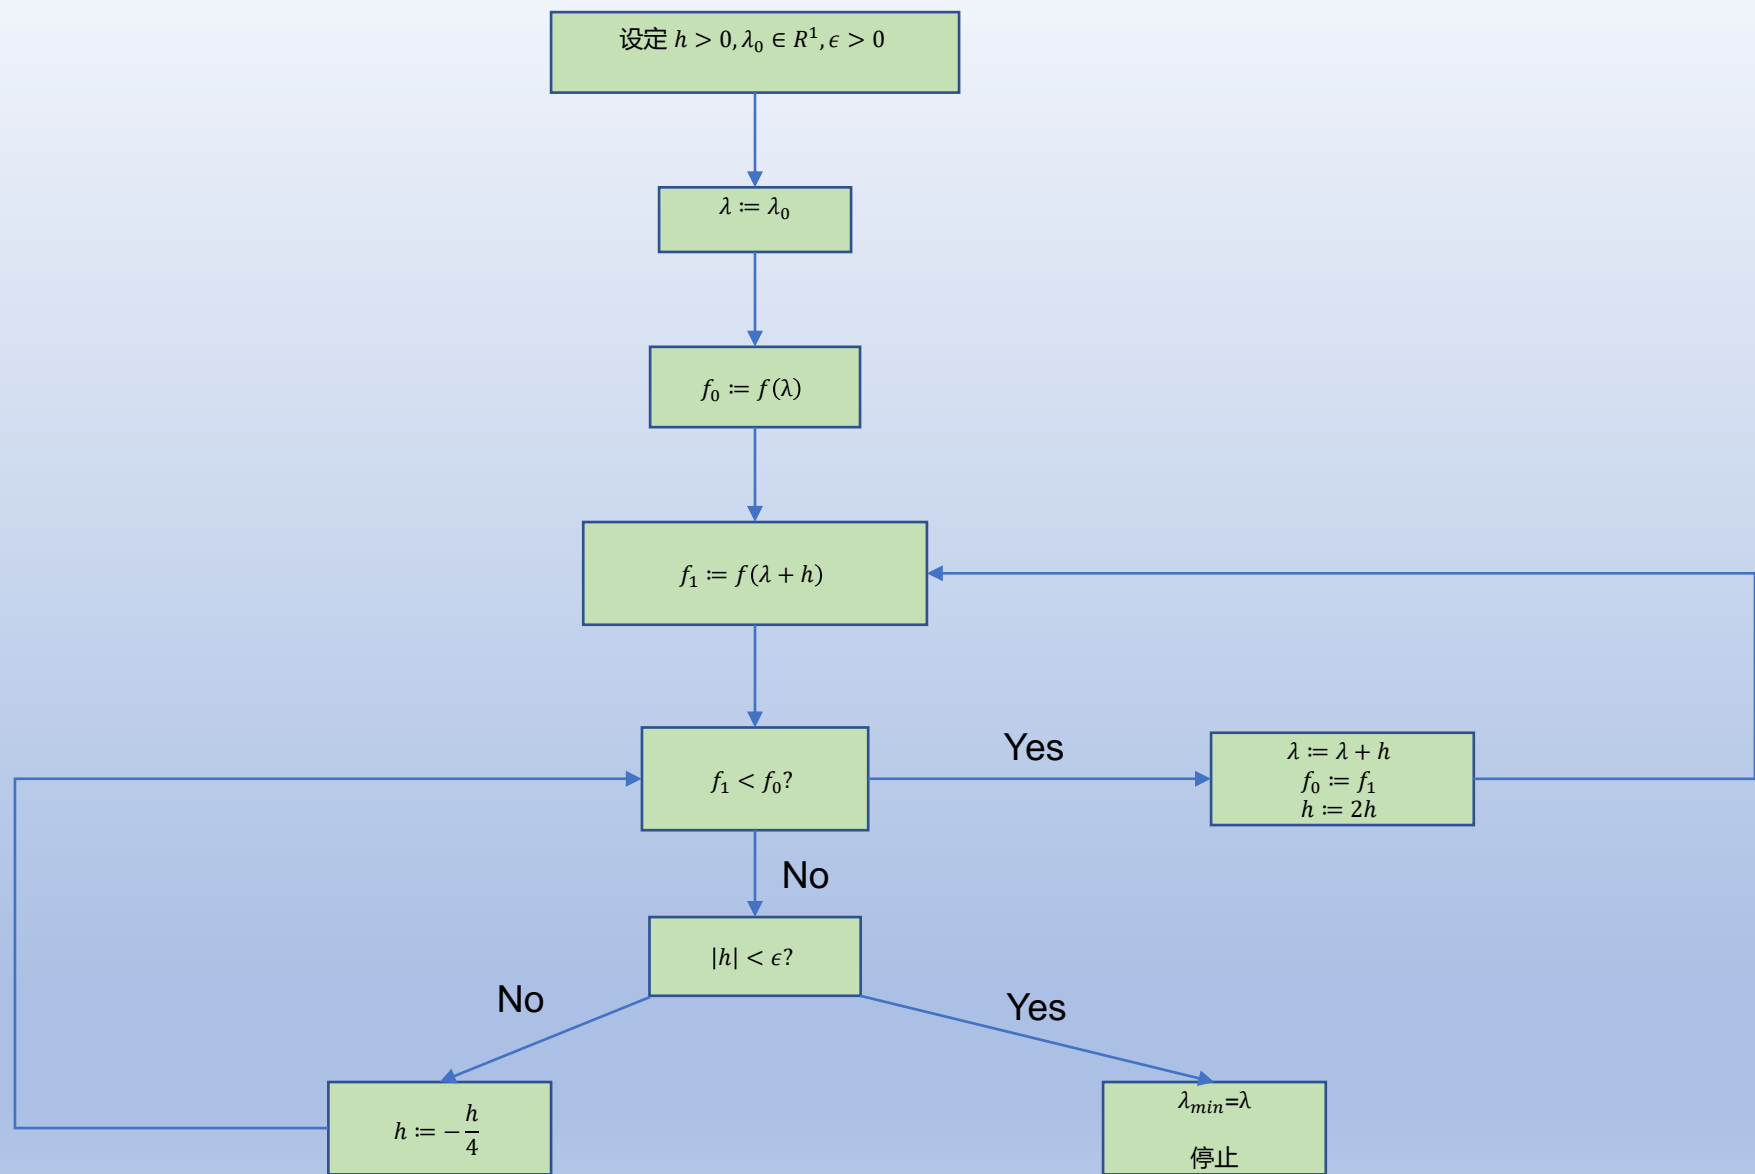


图3.4-1

### 3.4.2. 0.618法(优选法)


考虑问题

$$\min_{t \in [a, b]} f(t)$$

假设函数 $f$ 是区间 $[a, b]$ 上的下单峰函数, 它有唯一的极小点 $t^*$ . 函数在  $[a, t^*]$ 严格单调下降, 在 $[t^*, b]$ 严格单调递增.

若在此区间内任取两点 $a_1$ 和 $b_1$   $a_1 < b_1$  有如下情形:

1.  $f(a_1) < f(b_1)$  (图(a)), 这时极点 $t^*$ 在区间 $[a, b_1]$ 中.
2.  $f(a_1) \geq f(b_1)$  (图(b)), 这时极点 $t^*$ 在区间 $[a_1, b]$ 中.




这说明, 只要在区间  $[a, b]$  内取两个不同点, 并算出它们的函数值加以比较, 就可以把搜索区间  $[a, b]$  缩小成  $[a, b_1]$  或  $[a_1, b]$  (缩小后的区间仍需包含极小点).

如果要继续缩小搜索区间  $[a, b_1]$  或  $[a_1, b]$ , 就只需在上述区间内再取一点算出其函数值, 并与  $f(a_1)$  或  $f(b_1)$  加以比较即可. 只要缩小后的区间包含极小点  $t^*$ , 则区间缩小得越小, 就越接近于函数的极小点, 但计算函数值的次数也就越多. 自然希望以恰当的方式选择点, 使得以较少的计算次数, 能够尽快地缩短区间.

“0.618法”是一种高效地缩短包含极值点区间的算法. 每次把点  $a_1, b_1$  分别取在当前区间  $[a, b]$  的0.382和0.618处, 即

$$a_1 = a + 0.382(b - a)$$

$$b_1 = a + 0.618(b - a)$$



注：黄金分割数  
0.618满足方程  
 $x^2 = 1 - x$

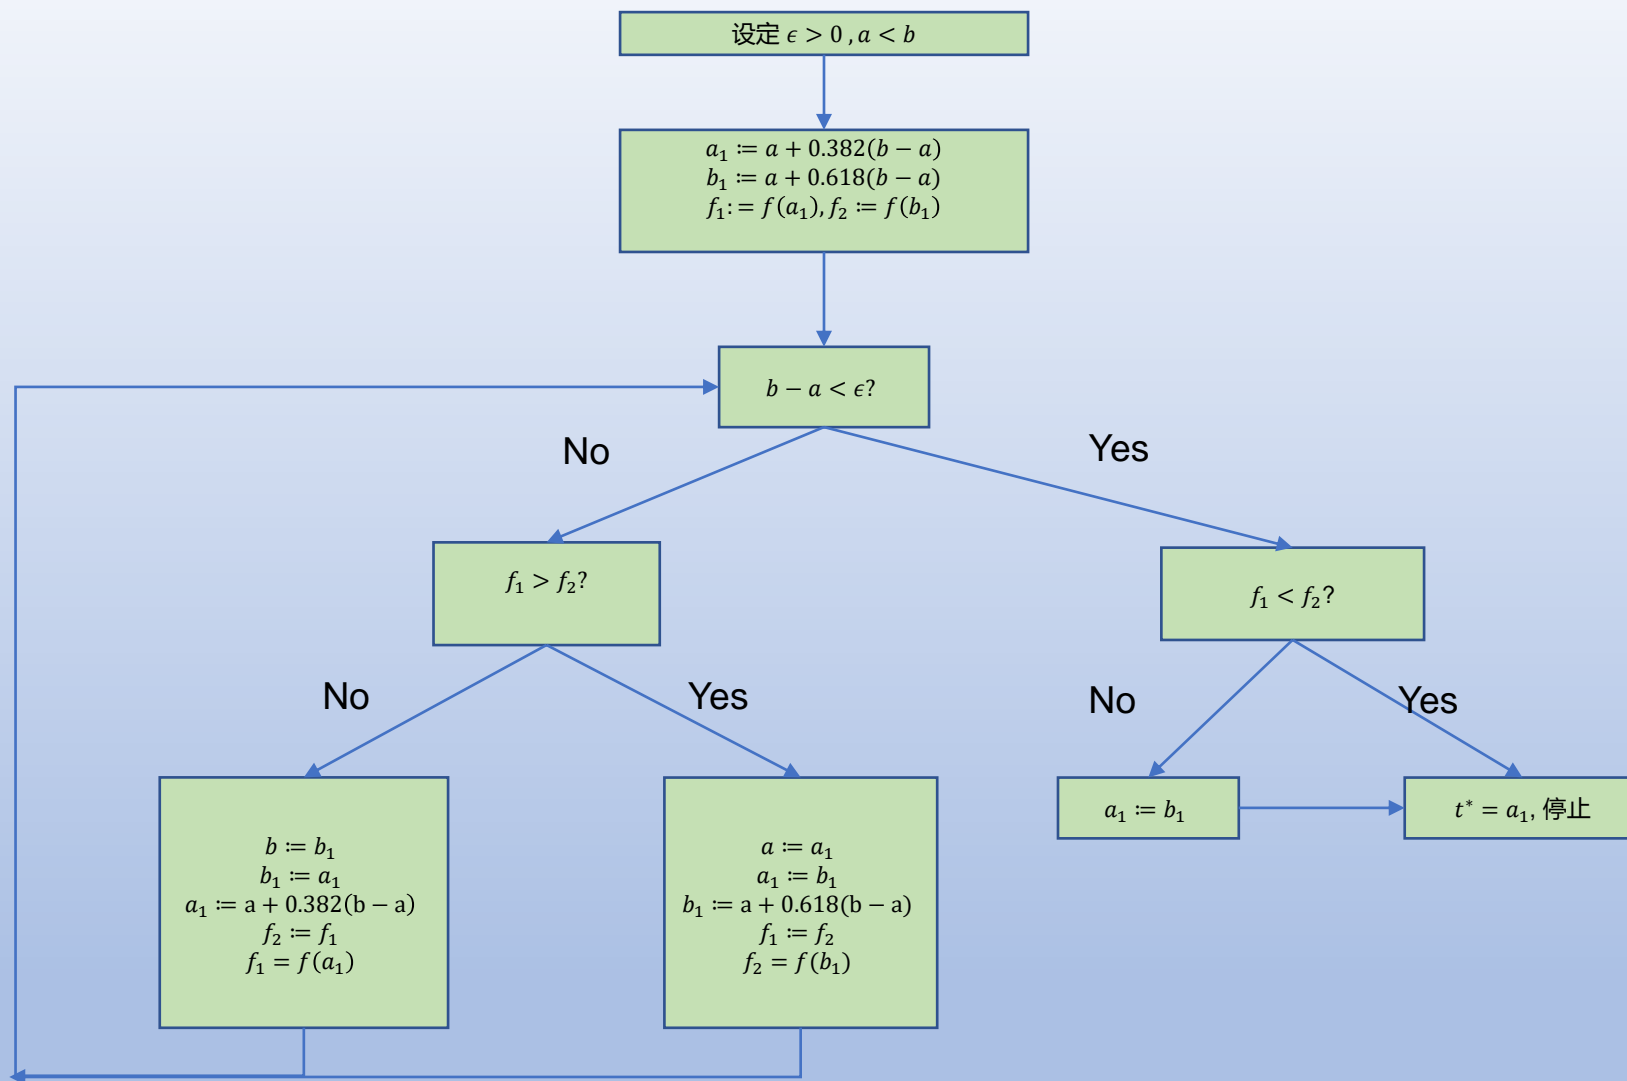


图3.4-2



### 3.4.3 二次插值法

想法：用一个二次函数近似原函数，用二次函数的极点近似原函数的极点.

考虑  $\min_{\lambda \geq 0} f(\lambda)$

这里假设  $\frac{df}{d\lambda}(0) < 0$ . 寻找二次函数  $g(x) = a_0 + a_1\lambda + a_2\lambda^2$  近似  $f$ . 那么  $g$  的极小点为  $\bar{\lambda} = -a_1/2a_2$

为了找到合理的二次函数系数  $a_0, a_1, a_2$ , 我们需要找到  $\lambda_0 > 0$  满足:

$$f(0) \geq f(\lambda_0), f(2\lambda_0) \geq f(\lambda_0)$$

那么对三个点  $0, \lambda_0, 2\lambda_0$  进行二次插值:

$$\begin{cases} a_0 & = f(0) \\ a_0 + a_1\lambda_0 + a_2\lambda_0^2 & = f(\lambda_0) \\ a_0 + 2a_1\lambda_0 + 4a_2\lambda_0^2 & = f(2\lambda_0) \end{cases}$$



求得

$$\lambda_{\min} \sim \bar{\lambda} = \frac{4f(\lambda_0) - 3f(0) - f(2\lambda_0)}{2(2f(\lambda_0) - f(0) - f(2\lambda_0))} \lambda_0$$

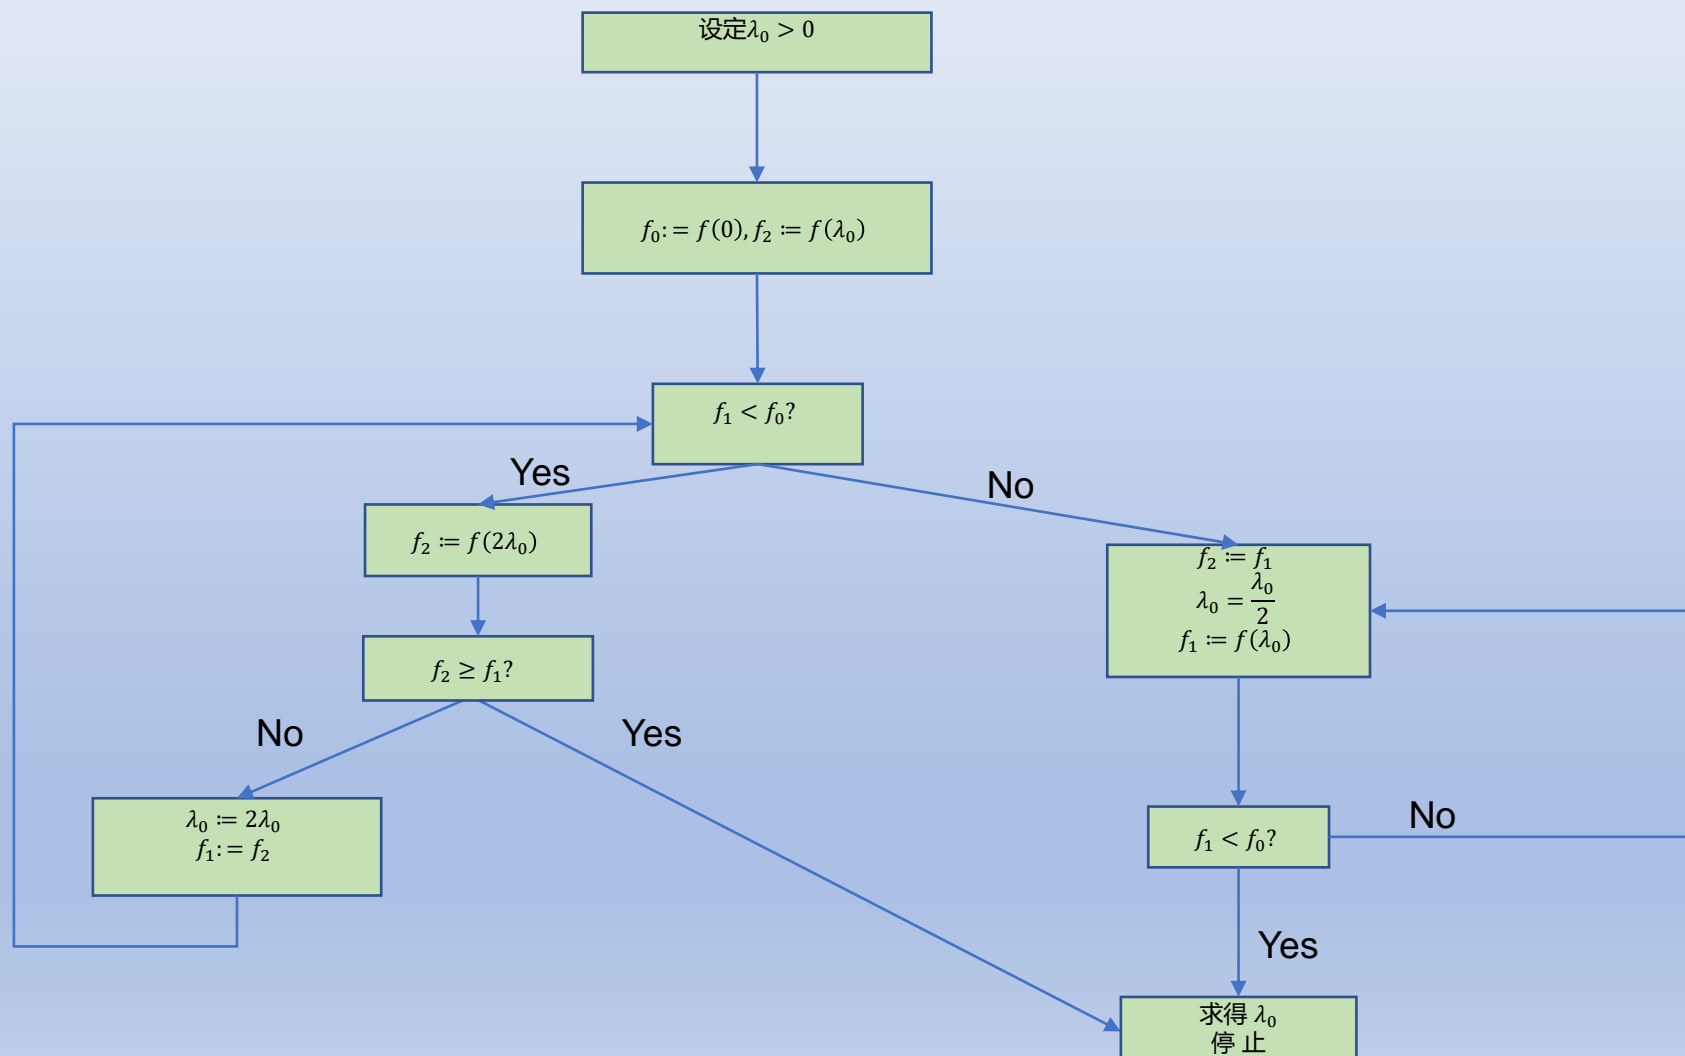


图3.4-3

## 3.5 无约束极值问题的解法

### 3.5.1 最速下降法

考虑问题无约束极值问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

假设目标函数具有连续的一阶偏导函数。那么：

- 任何局部极点 $x_0$ 一定是临界点，即 $\nabla f(x_0)=0$ .
- 若 $\nabla f(x_0) \neq 0$ , 那么向量 $-\nabla f(x_0)$ 给出函数值下降最快的方向(局部上)

基于如上考虑，最速下降法就是在一点处求梯度向量，再延起负梯度方向，求对应一元函数的最小值。不断迭代，得到趋于极值点的序列.

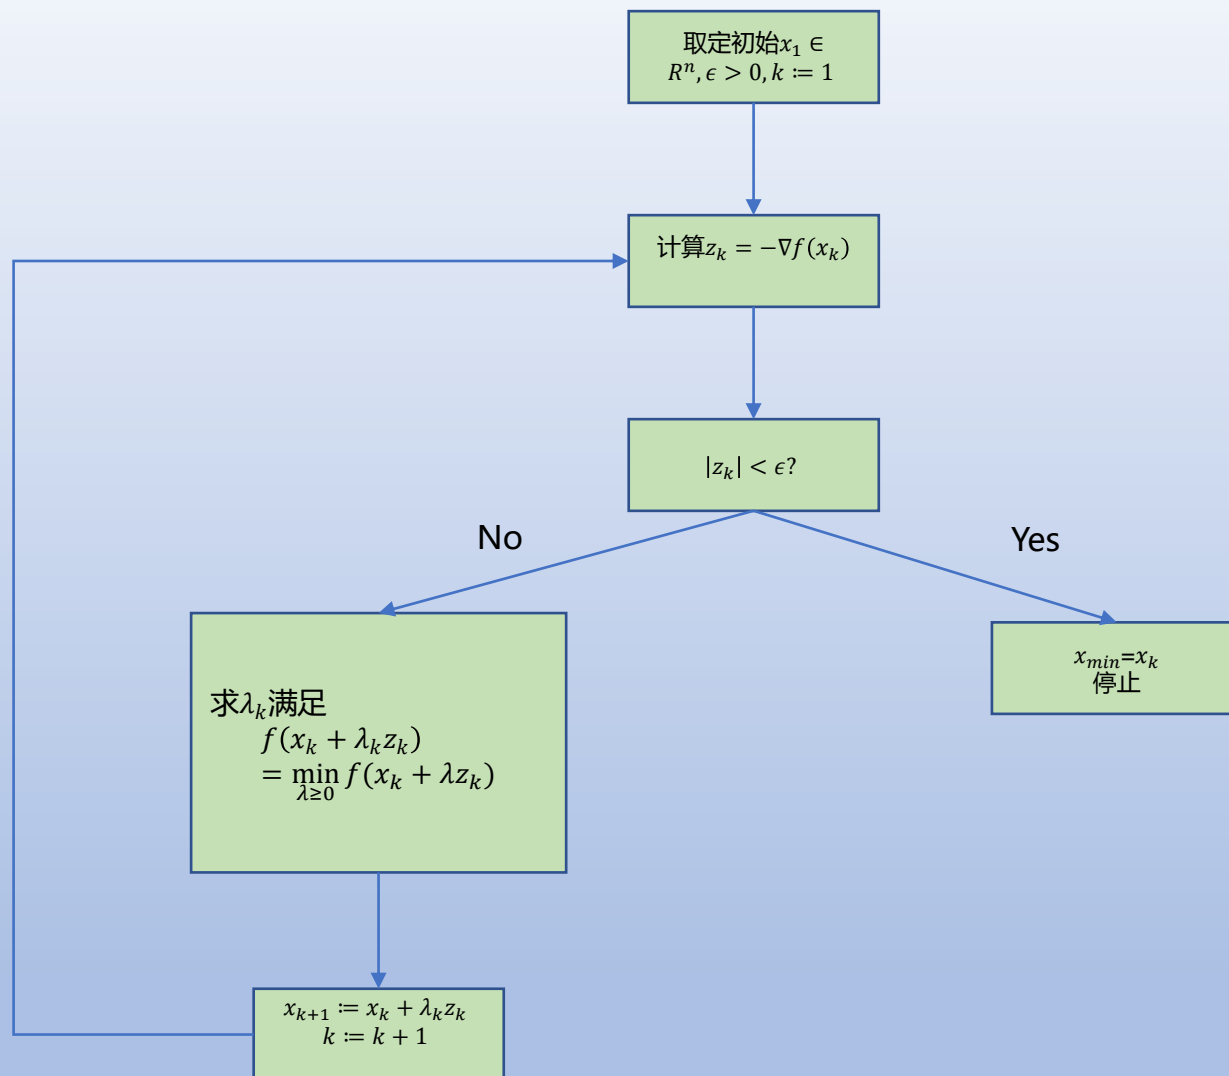


图3.5-1

## 3.5.2 广义牛顿法

考虑优化问题

$$\min_{x \in \mathbb{R}^n} f(x)$$

假设 $f$ 有连续的二阶偏导函数, 且极小值点 $x_0$ 处海赛矩阵 $H(f) = [\frac{\partial^2 f}{\partial x_i \partial x_j}]$  为对称正定矩阵.

首先考虑

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2}x^T Cx + p^T x$$

这里 $C$ 是对称正定 $n$ 阶矩阵,  $p \in \mathbb{R}^n$ .

$f$ 任意点处的海赛矩阵是 $C$ , 所以是严格凸函数, 所以其局部最优点也是全局最优点. 令

$$\nabla f = Cx + p = 0$$

得最优解

$$x_0 = -C^{-1}p$$

对于任意  $x \in R^n$ , 最优解到  $x$  的位移向量为

$$\begin{aligned}x_0 - x &= -C^{-1}p - x \\&= -C^{-1}(p + Cx) \\&= -C^{-1}\nabla f(x) \\&= -(Hf(x))^{-1}\nabla f(x)\end{aligned}$$

注意：向量  $-(Hf(x))^{-1}\nabla f(x)$  给出了从  $x$  出发，到最优解  $x_0$  的方向.

对于一般的满足假设的函数  $f$ ，在最优解  $x_0$  附近，利用多元函数的Taylor展开，有

$$\begin{aligned}& f(x) \\&= f(x_0) + (\nabla f(x_0))^T(x - x_0) + \frac{1}{2}(x - x_0)^T Hf(x_0)(x - x_0) + o(|x - x_0|^2) \\&\sim f(x_0) + (\nabla f(x_0))^T(x - x_0) + \frac{1}{2}(x - x_0)^T Hf(x_0)(x - x_0)\end{aligned}$$

利用情形  $\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2}x^T Cx + p^T x$  得到的“指引”向量，结合一维搜索有广义牛顿算法：

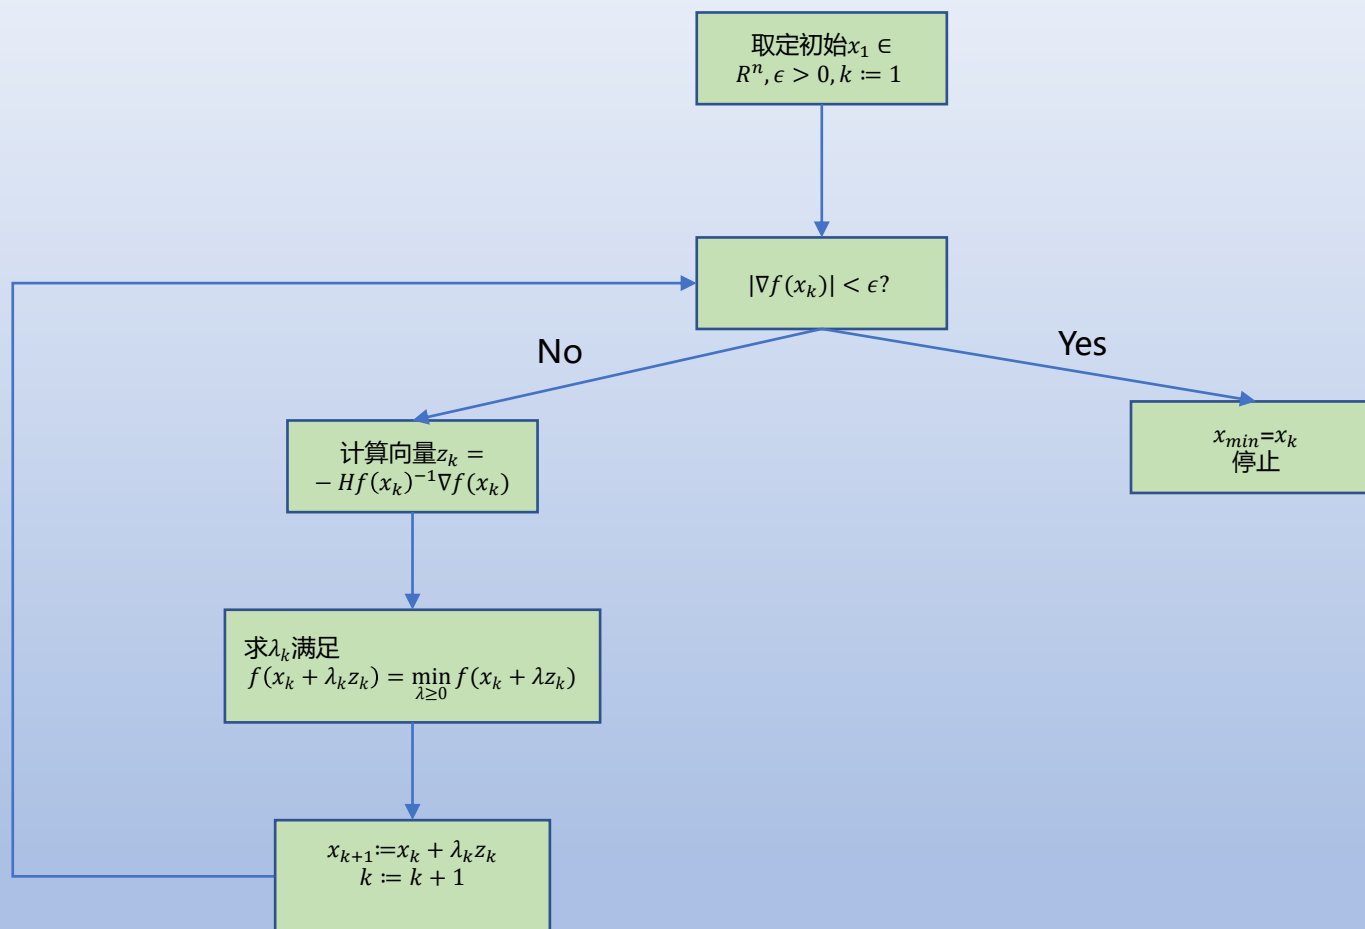


图3.5-2



## 3.6 罚函数方法

介绍求解非线性规划问题的罚函数法. 使用这种方法, 可将非线性规划问题的求解, 转化为求解一系列无约束极值问题.

罚函数法的经济解释:

将目标函数 $f(x)$ 看成“价格”, 约束条件看成某种“规定”, 采购人需要在规定范围内购置最便宜的东西. 管理者对违反规定制定了一种“惩罚”机制. 若符合规定, 罚款为零. 否则, 要收取罚款. 此时, 采购人付出的总代价应是价格和罚款的总和. 采购者的目标是使总代价最小, 这是一个无约束问题. 当罚款规定得很苛刻时, 违反规定支付的罚款很高, 这就迫使采购人符合规定. 数学上的表现为当惩罚因子 $M$ 足够大时, 无约束问题的最优解应满足约束条件, 而成为约束问题的最优解.

简单情形

$$\begin{cases} \min f(x) \\ g(x) = 0 \end{cases}$$

可行解集  $R = \{x \mid g(x) = 0\}$ . 取定非常大的整数  $M > 0$ . 直观上, 如果  $x \notin R$ , 那么  $x$  不太可能是无约束极值问题

$$\min_{x \in \mathbb{R}^n} T(x, M) = f(x) + M g(x)^2$$

的最优解. 如果是最优解, 也一定离可行集  $R$  很近.

注意到

$$T(x, M) \begin{cases} = f(x) & x \in R \\ > f(x) & x \notin R \end{cases}$$

如果无约束极值问题的最优解  $x_0 \in R$ , 那么  $x_0$  也是原问题的最优解.

处理一般不等式约束, 只需注意到

$$g(x) \geq 0 \Leftrightarrow \min(0, g(x)) = 0$$

罚函数法迭代步骤:

(1) 取  $M_1 > 0$  以及允许误差  $\epsilon > 0$ , 并令  $k:=1$

(2) 求无约束极值问题的最优解:

$$\min_{x \in \mathbb{R}^n} T(x, M_k) = T(x^k, M_k)$$

其中

$$T(x, M_k) = f(x) + M_k \sum_{j=1}^m [\min(0, g_j(x))^2]$$

(3) 若对某一个  $j (1 \leq j \leq m)$  有  $g_j(x^k) \leq -\epsilon$ , 则取  $M_{k+1} > M_k$

(例如  $M_{k+1} = cM_k, c = 10$ ), 令  $k:=k+1$

并转向第2步. 否则, 停止迭代, 得近似解

$$x_{\min} \sim x^k$$

### 例1 求解非线性规划

$$\begin{cases} \min f(x) &= x_1 + x_2 \\ g_1(x) &= -x_1^2 + x_2 \geq 0 \\ g_2(x) &= x_1 \geq 0 \end{cases}$$

解：构造罚函数

$$\begin{aligned} T(x, M) &= f(x) + M\{[\min(0, g_1(x))]^2 + [\min(0, g_2(x))]^2\} \\ &= x_1 + x_2 + M\{[\min(0, -x_1^2 + x_2)]^2 + [\min(0, x_1)]^2\} \end{aligned}$$

求  $\min_{x \in \mathbb{R}^2} T(x, M)$

$$\begin{aligned} \frac{\partial T}{\partial x_1} &= 1 + 2M\{[\min(0, g_1(x))(-2x_1)] + \min(0, g_2(x))\} \\ \frac{\partial T}{\partial x_2} &= 1 + 2M[\min(0, -x_1^2 + x_2)] \end{aligned}$$

令  $\frac{\partial T}{\partial x_1} = \frac{\partial T}{\partial x_2} = 0$  , 得

$$X(M) = -\left(\frac{1}{2(1+M)}, \left(\frac{1}{4(1+M)^2} - \frac{1}{2M}\right)\right)^T$$

取  $M = 1, 2, 3, 4$  , 可得出以下结果:

$$M = 1, \quad X = (-1/4, -7/16)^T$$

$$M = 2, \quad X = (-1/6, -2/9)^T$$

$$M = 3, \quad X = (-1/8, -29/192)^T$$

$$M = 4, \quad X = (-1/10, -23/200)^T$$

可知  $X(M)$  从  $R$  的外面逐步逼近  $R$  的边界, 当  $M \rightarrow \infty$  时,  
 $X(M)$  趋于原问题的极小解  $X_{\min} = (0, 0)^T$




图3.6-1